


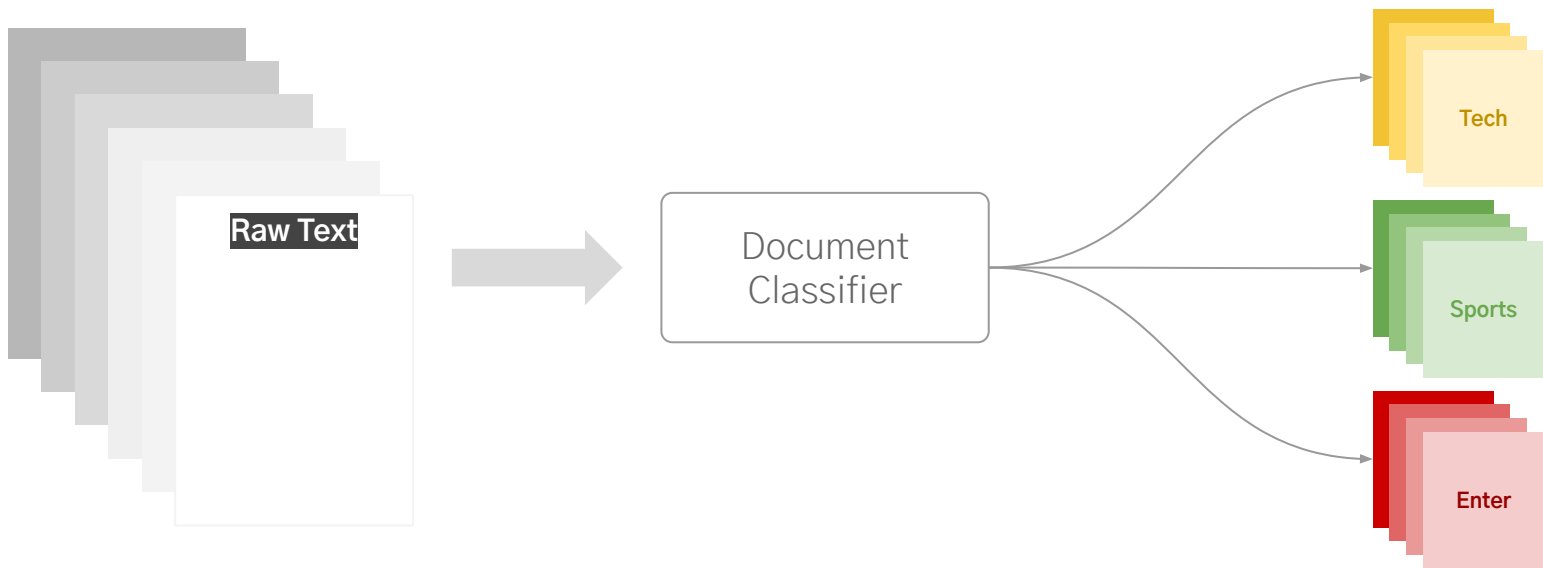
문서 분류 (Document Classification)

실무형 인공지능 자연어처리



문서 분류

- 문서를 사전에 구성된 그룹으로 분류하는 모델
 - 카테고리 분류, 감정 분석, 언어 탐지 등
- 텍스트 분류는 텍스트를 빠르고 비용 효율적으로 적용이 가능




분류 모델(1) - 나이브 베이즈 분류

- 베이즈 정리를 사용하는 분류 모델
- 학습 데이터에서 추출한 이미 알고 있는 사전 확률을 바탕으로 사후 확률을 계산하여 분류
- 성능 개선을 위한 방법
 - 불용어 처리 : 분류를 판단하는데 불필요한 단어 제거
 - 원형복원 : 같은 의미의 다른 표현을 원형복원하여 표준화
 - N-gram : n개의 단어 묶음. 문맥을 포함할 수 있음
 - TF-IDF : 단순 빈도 기반이 아니라 문서 빈도-역문서 빈도에 기반하여 각 단어의 점수를 결정


분류 모델(2) - 서포트 벡터 머신

- SVM(Support Vector Machines)은 제한된 양의 데이터를 처리 할 때 좋은 성능을 보이는 분류 알고리즘
- 주어진 그룹에 속하는 벡터와 그룹에 속하지 않은 벡터 간 분류를 결정
- SVM는 많은 학습데이터가 필요하지 않지만, 나이브 베이즈 분류보다 좋은 성능을 내기 위해서는 더 많은 계산 리소스가 필요




분류 모델(3) - 딥러닝

- 분류에에는 널리 사용되는 주요 딥러닝 모델인 CNN, RNN, Transformer 기반 모델
 - CNN은 입력 레이어, 출력 레이어 및 컨볼루션 레이어로 구성된 딥러닝 모델



- RNN은 시퀀스 정보를 처리하는 딥러닝 모델. RNN은 이전 계산 결과를 기억하여 현재 계산에 사용.



- 딥러닝은 데이터가 많을 수록 잘 작동하기 때문에 잘 태깅된 데이터가 필수

문서 분류 (Document Classification)

통계기반 자연어 처리

1

베이지스 분류기 (Bayes Classifier)



Bayes Classifier

- 데이터의 조건부 확률에 기반한 분류 => 데이터 중심
- 범주형 자료에만 적용 가능 : 수치형 자료(예.키, 몸무게, 주가 등)는 범주형으로 변환 필요
- 좋은 성능을 위해서는 대량 데이터가 필요
- 종류
 - Exact Bayes Classifier
 - 조건부 확률과 베이지 확률에 기반
 - 조건이 많으면 계산이 어려움
 - Naive Bayes Classifier
 - 독립변수가 많을때 간단히 계산

확률

- 확률이란
 - 어떤 사건이 발생할 가능성(사건 결과의 비율)
 - **확률 = 가능성 = %**
 - 어떤 사건이 발생할 가능성을 0 ~ 1 값으로 표현한 것
- 확률 계산
 - $P(A) = n_A/n_S = A\text{의개수}/S\text{의개수} = \text{관심사건}(A)/\text{표본공간}(S) = \%$
 - S : 표본 공간 (Sample space)
 - A : 사건(event)

$$P(A) = \frac{\text{관심사건}(A)}{\text{표본공간}(S)} = \frac{A\text{의개수}}{S\text{의개수}} = \frac{n_A}{n_S}$$



조건부 확률

- 조건부 확률(Conditional probability)이란?
 - $P(A)$, $P(B)$ 두 개의 사건이 발생함
 - $P(B|A) =$
 - A 조건이 주어진 상태에서 B가 발생 할 확률
- 사례
 - (확률) 동전 2번 던졌을 때 모두 앞면이 나오는 경우
 - $S = [HH, HT, TH, TT]$, $A=[HH]$
 - $P(A) = \frac{1}{4} = 0.25$
 - (조건부 확률) 동전 하나는 이미 앞면이라고 알고 있는 경우
 - $S = [HH, HT, TH]$, $A=[HH]$
 - $P(A) = \frac{1}{3} = 0.3333$

조건부 확률

- 조건부 확률(Conditional probability)이란?
 - A라는 추가 조건이 주어진 상태에서 다른 사건 B가 발생 할 확률
 - 표본공간(S)이 바뀜

$$P(B | A) = \frac{n(A \cap B)}{n(A)} = \frac{P(A \cap B)}{P(A)}$$




$$P(A) = \frac{n_A}{n_S} = \frac{60}{160} = 0.375 = 37.5 \%$$


표본공간(S)가 변경 (160 -> 60)

$$P(B | A) = \frac{n_{A \cap B}}{n_A} = \frac{10}{60} = 0.167 = 16.7 \%$$


조건부 확률



$$P(A \cap B) = \frac{10}{50+10+100} = \frac{10}{160} = 0.0625 = 6.25 \%$$




$$P(B | A) = \frac{P(A \cap B)}{P(A)} = \frac{10}{60} = 0.167 = 16.7 \%$$



$$P(A | B) = \frac{P(A \cap B)}{P(B)} = \frac{10}{110} = 0.091 = 9.1 \%$$


조건부 확률

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$



$$P(A \cap B) = P(A) \cdot P(B | A) = \frac{60}{160} \cdot \frac{10}{60} = \frac{10}{160}$$

$$P(A \cap B) = P(B) \cdot P(A | B) = \frac{110}{160} \cdot \frac{10}{110} = \frac{10}{160}$$



- $P(A \cap B)$ 는 조건부 확률의 순차적 곱으로 분해 가능
- 복잡한 사건을 분해해서 사용

예제 : 사기 재무보고 예측

- 사기 재무보고 예측
 - 이전 법적문제를 가지고 있는 기업의 경우 사기일 확률은?
 - 사건 A = [사기(fraud), 정직(honest)]
 - 사건 B = [이전 법적문제 유(yes), 이전 법적문제 무(no)]

	이전 법적문제 유(yes)	이전 법적문제 무(no)	계
사기(fraud)	50	50	100
정직(honest)	180	720	900
계	230	770	1,000

$$P(fraud \mid yes) = \frac{50}{230} = 0.22 = 22 \%$$

$$P(fraud) = \frac{100}{1000} = 0.1$$

예제 : 사기 재무보고 예측

- 사기 재무보고 예측
 - 조건이 여러개인 경우?
 - $P(\text{사기} \mid \text{이전법적문제}=\text{yes}, \text{회사규모}=\text{small}) = 1/2 = 50\%$
 - $P(\text{사기} \mid \text{이전법적문제}=\text{no}, \text{회사규모}=\text{small}) = 0/3 = 0\%$

회사	이전 법적문제	회사규모	상태
1	yes	small	정직
2	no	small	정직
3	no	large	정직
4	no	large	정직
5	no	small	정직
6	no	small	정직
7	yes	small	사기
8	yes	large	사기
9	no	large	사기
10	yes	large	사기

2

나이브 베이즈 분류 (Naive Bayes Classifier)



나이프 베이즈 분류(Naive Bayes Classifier)

기계 학습분야에서, '나이프 베이즈 분류(Naïve Bayes Classification)는 **특성들 사이의 독립을 가정하는 베이즈 정리를 적용한 확률 분류기의 일종으로 1950년대 이후 광범위하게 연구되고 있다.**


통계 및 컴퓨터 과학 문헌에서, 나이브 베이즈는 단순 베이즈, 독립 베이즈를 포함한 다양한 이름으로 알려져 있으며, 1960년대 초에 텍스트 검색 커뮤니티에 다른 이름으로 소개되기도 하였다.

나이프 베이즈 분류는 텍스트 분류에 사용됨으로써 문서를 여러 범주 (예: 스팸, 스포츠, 정치)중 하나로 판단하는 문제에 대한 대중적인 방법으로 남아있다. 또한, 자동 의료 진단 분야에서의 응용사례를 보면, 적절한 전처리를 하면 더 진보된 방법들 (예: 서포트 벡터 머신 (Support Vector Machine))과도 충분한 경쟁력을 보임을 알 수 있다.

https://ko.wikipedia.org/wiki/%EB%82%98%EC%9D%B4%EB%B8%8C_%EB%B2%A0%EC%9D%B4%EC%A6%88_%EB%B6%84%EB%A5%98

나이브베이즈 분류기 활용 감성분석

- 감성분석도 분류 문제의 하나로 볼 수 있음
- 따라서 분류모델을 활용하여 감성분석이 가능함. 대신 감정라벨이 부착된 학습용 데이터가



베이즈 정리

- 베이즈 정리(Bayes' Rule) : 사전 확률과 사후확률 사이의 관계를 조건부 확률을 이용해 계산하는 확률 이론

$$\overset{\text{사후확률}}{P(c \mid x_1, x_2, \dots, x_n)} = \frac{\overset{\text{우도(가능도)}}{P(x_1, x_2, \dots, x_n \mid c)} \cdot \overset{\text{사전확률}}{P(c)}}{\underset{\text{증거}}{P(x_1, x_2, \dots, x_n)}}$$

$$P(x_1, x_2, \dots, x_n \mid c) = P(x_1 \mid c) \cdot P(x_2 \mid c) \cdot \dots \cdot P(x_n \mid c)$$

$$P(c \mid x_1, x_2, \dots, x_n) = \frac{(P(x_1 \mid c) \cdot P(x_2 \mid c) \cdot \dots \cdot P(x_n \mid c)) \cdot P(c)}{P(x_1, x_2, \dots, x_n)}$$

베이즈 정리

- 베이즈 정리(Bayes' Rule): 사전 확률과 사후확률 사이의 관계를 조건부 확률을 이용해 계산하는 확률 이론

우도(가능도)

$$P(c \mid x_1, x_2, \dots, x_n) = \frac{P(x_1, x_2, \dots, x_n \mid c) \cdot P(c)}{P(x_1, x_2, \dots, x_n)}$$

우도의

조건부 독립가정

$$P(x_1, x_2, \dots, x_n \mid c) = P(x_1 \mid c) \cdot P(x_2 \mid c) \cdot \dots \cdot P(x_n \mid c)$$

$$P(c \mid x_1, x_2, \dots, x_n) = \frac{(P(x_1 \mid c) \cdot P(x_2 \mid c) \cdot \dots \cdot P(x_n \mid c)) \cdot P(c)}{P(x_1, x_2, \dots, x_n)}$$

$$P(A, B \mid C) = P(A \mid C) \cdot P(B \mid C)$$

베이즈 정리


- 베이즈 정리(Bayes' Rule) : 사전 확률과 사후확률 사이의 관계를 조건부 확률을 이용해 계산하는 확률 이론
- 사전 확률(prior probability)
 - 이미 알고 있는 사건이 발생할 확률
- 우도(likelihood probability)
 - 이미 알고 있는 사건이 발생한다는 조건하에 다른 사건이 발생할 확률
- 사후 확률(posterior probability)
 - 사전확률과 우도를 통해서 알게되는 조건부 확률

베이즈 정리(Bayes' theorem)

확률론과 통계학에서, 베이즈 정리(영어: Bayes' theorem)는 두 확률 변수의 사전 확률과 사후 확률 사이의 관계를 나타내는 정리다. 베이즈 확률론 해석에 따르면 베이즈 정리는 사전확률로부터 사후확률을 구할 수 있다.

빨 간 색 영역 = $P(A_1 \cap B) = P(B | A_1) \cdot P(A_1)$

파 란 색 영역 = $P(A_2 \cap B) = P(B | A_2) \cdot P(A_2)$



사후확률(posterior probability)

$$P(A_1|B) = \frac{P(B \cap A_1)}{P(B)}$$

$$= \frac{P(B|A_1)P(A_1)}{P(B)}$$

$$= \frac{P(B|A_1)P(A_1)}{P(B|A_1)P(A_1) + P(B|A_2)P(A_2)}$$

우도(likelihood probability)

사전확률(prior probability)

베이즈 정리

- 베이즈 정리(Bayes' Rule)
 - 사전 확률과 사후확률 사이의 관계를 조건부 확률을 이용해 계산하는 확률 이론
- 확률 종류
 - 사전(prior) 확률 : $P(A)$
 - 우도(likelihood) 확률 : $P(B|A) = P(A \cap B) / P(A)$
 - 사후(posterior) 확률 :
 - $P(A|B) = P(A \cap B) / P(B)$
 - $P(A \cap B) = P(B|A) \times P(A)$
 - $P(B) = P(A)P(B|A) + P(A')P(B|A')$
 - $P(A|B) = P(A \cap B) / P(B) = [P(B|A) \times P(A)] / [P(A)P(B|A) + P(A')P(B|A')]$

예제 : Naive Bayes Classifier

- 예제
 - 김여사 유방조영술을 통해 유방암 검사를 받았는데, 검사결과가 양성(Positive)라고 검진되었음
 - 유방암에 걸렸을 때, 유방조영술을 통해 양성(Positive)으로 나올 확률은 90%
 - 유방암이 아니더라도 유방조영술이 양성일 확률은 7%
 - 40-50대 여성이 유방암에 걸릴 확률은 0.8%
 - 김여사가 유방암에 걸렸을 확률은?

예제 : Naive Bayes Classifier

- 경우
 - $Y = [\text{암(cancer)}, \text{정상(normal)}]$
 - $X = [\text{양성(positive)}, \text{음성(negative)}]$

- 유방암에 걸릴 확률(사전 확률)

$$P(\text{cancer}) = 0.008$$

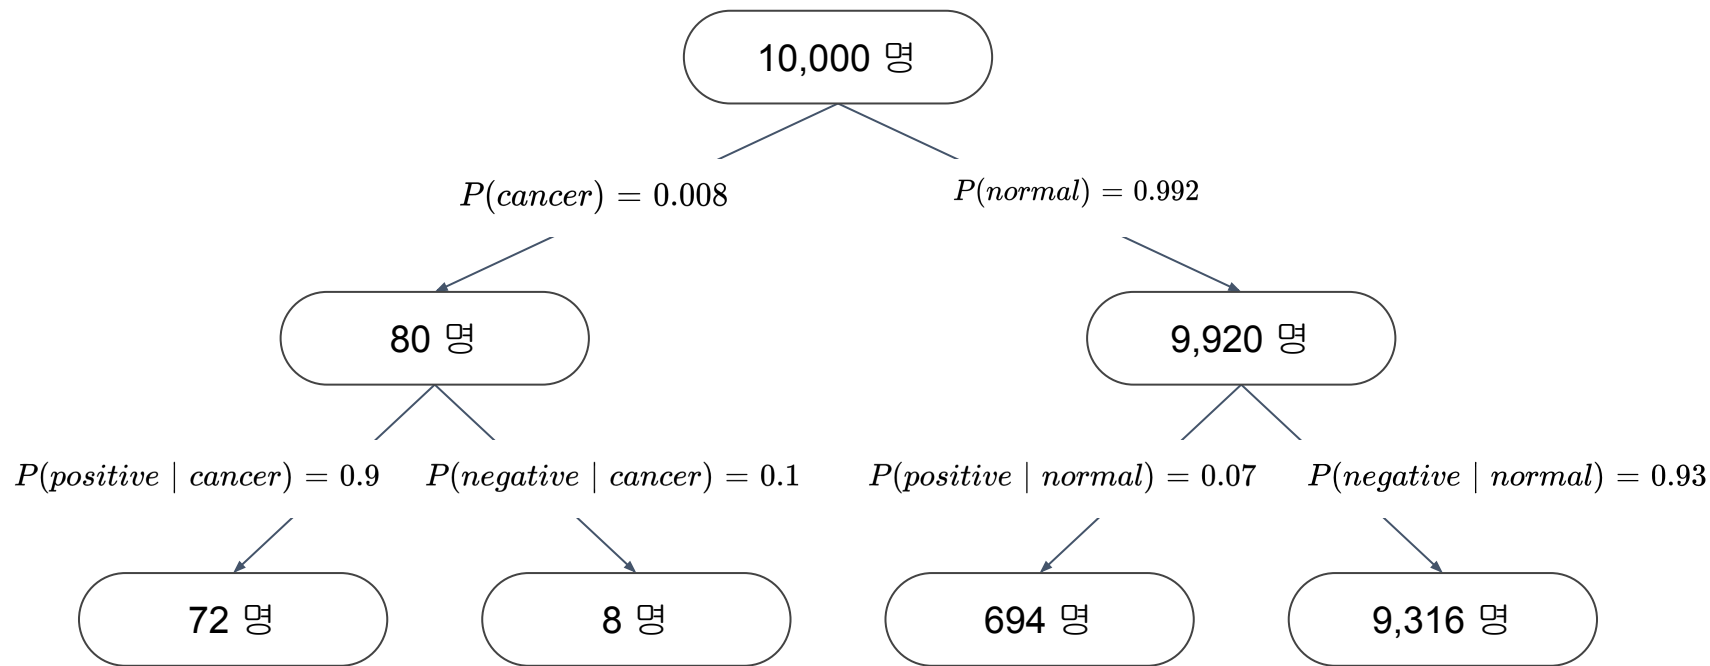
$$P(\text{normal}) = 1 - 0.008 = 0.992$$

- 우도

$$P(\text{positive} \mid \text{cancer}) = \frac{P(\text{cancer} \cap \text{positive})}{P(\text{cancer})} = 0.9$$

$$P(\text{positive} \mid \text{normal}) = \frac{P(\text{normal} \cap \text{positive})}{P(\text{normal})} = 0.07$$

예제 : Exact Bayes Classifier



예제 : Exact Bayes Classifier

$$P(\text{cancer} \mid \text{positive})$$

$$= \frac{P(\text{cancer})P(\text{positive}|\text{cancer})}{P(\text{cancer})P(\text{positive}|\text{cancer})+P(\text{normal})P(\text{positive}|\text{normal})}$$

$$= \frac{0.008 \cdot 0.9}{(0.008 \cdot 0.9) + (0.992 \cdot 0.07)}$$

$$= \frac{0.0072}{0.0072 + 0.0694}$$

$$= \frac{0.0072}{0.0766} = 0.0939$$

Naive Bayes Classifier란?

When

$X = \langle X_1, X_2, \dots, X_n \rangle$, X_i : discrete or continuous, Y : discrete

Naive Bayes classifier

$$\begin{aligned}
 P(Y = y_k | X_1 \dots X_n) &= \frac{P(Y = y_k) P(X_1 \dots X_n | Y = y_k)}{\sum_j P(Y = y_j) P(X_1 \dots X_n | Y = y_j)} \\
 &\stackrel{\text{Naive Bayes}}{=} \frac{P(Y = y_k) \prod_i P(X_i | Y = y_k)}{\sum_j P(Y = y_j) \prod_i P(X_i | Y = y_j)}
 \end{aligned}$$

Bayes

Conditional Independence

예제 : 사기 재무보고 예측

- 예제(사후확률) : $P_{nb}(\text{사기} | \text{이전법적문제}=\text{yes}, \text{회사규모}=\text{small})$
- 사기 인 경우
 - 사전 확률 : $P(\text{사기}) = 4/10 = 0.4$
 - 우도(조건부 확률)
 - $P(\text{이전법적문제}=\text{yes} | \text{사기}) = \frac{3}{4} = 0.75$
 - $P(\text{회사규모}=\text{small} | \text{사기}) = \frac{1}{4} = 0.25$
- 정직 인 경우
 - 사전 확률 : $P(\text{정직}) = 1 - 0.4 = 0.6$
 - 우도(조건부 확률)
 - $P(\text{이전법적문제}=\text{yes} | \text{정직}) = 1/6 = 0.17$
 - $P(\text{회사규모}=\text{small} | \text{정직}) = 4/6 = 0.67$

회사	이전 법적문제	회사규모	상태
1	yes	small	정직
2	no	small	정직
3	no	large	정직
4	no	large	정직
5	no	small	정직
6	no	small	정직
7	yes	small	사기
8	yes	large	사기
9	no	large	사기
10	yes	large	사기

예제 : 사기 재무보고 예측

- 예제(사후확률) :

$$\begin{aligned}
 &P(\text{사기} \mid \text{이전법전문제} = \text{yes}, \text{회사규모} = \text{small}) \\
 &= \frac{P(\text{Fraud}) \cdot P(\text{Yes}|\text{Fraud}) \cdot P(\text{Small}|\text{Fraud})}{P(\text{Fraud}) \cdot P(\text{Yes}|\text{Fraud}) \cdot P(\text{Small}|\text{Fraud}) + P(\text{Normal}) \cdot P(\text{Yes}|\text{Normal}) \cdot P(\text{Small}|\text{Normal})} \\
 &= \frac{0.4 \cdot 0.75 \cdot 0.25}{(0.4 \cdot 0.75 \cdot 0.25) + (0.6 \cdot 0.17 \cdot 0.67)} = 0.53
 \end{aligned}$$

	정직(0.6)	사기(0.4)	P(x 정직)	P(x 사기)
법적(yes)	1	3	1/6 = 0.17	3/4 = 0.75
법적(no)	5	1	5/6 = 0.83	1/4 = 0.25
규모(small)	4	1	4/6 = 0.67	1/4 = 0.25
규모(large)	2	3	2/6 = 0.33	3/4 = 0.75

- Exact bayes classifier
 - P(사기|이전법전문제=yes, 회사규모=small)
= 1/2 = 0.5

회사	이전 법적문제	회사규모	상태
1	yes	small	정직
2	no	small	정직
3	no	large	정직
4	no	large	정직
5	no	small	정직
6	no	small	정직
7	yes	small	사기
8	yes	large	사기
9	no	large	사기
10	yes	large	사기

예제 : 사기 재무보고 예측

- 예제(사후확률) :
 - $P_{nb}(\text{사기} | \text{이전법전문제=no, 회사규모=small}) = ?$
 - $P_{nb}(\text{정직} | \text{이전법전문제=no, 회사규모=small}) = ?$

	정직(0.6)	사기(0.4)	$P(x \text{정직})$	$P(x \text{사기})$
법적(yes)	1	3	$1/6 = 0.17$	$3/4 = 0.75$
법적(no)	5	1	$5/6 = 0.83$	$1/4 = 0.25$
규모(small)	4	1	$4/6 = 0.67$	$1/4 = 0.25$
규모(large)	2	3	$2/6 = 0.33$	$3/4 = 0.75$

회사	이전 법적문제	회사규모	상태
1	yes	small	정직
2	no	small	정직
3	no	large	정직
4	no	large	정직
5	no	small	정직
6	no	small	정직
7	yes	small	사기
8	yes	large	사기
9	no	large	사기
10	yes	large	사기

예제 : 사기 재무보고 예측

- $P_{nb}(\text{사기} | \text{이전법전문제=no, 회사규모=small}) = ?$

$$= \frac{\frac{4}{10} \cdot \frac{1}{4} \cdot \frac{1}{4}}{\left(\frac{4}{10} \cdot \frac{1}{4} \cdot \frac{1}{4}\right) + \left(\frac{6}{10} \cdot \frac{5}{6} \cdot \frac{4}{6}\right)} = 0.07$$

- $P_{nb}(\text{정직} | \text{이전법전문제=no, 회사규모=small}) = ?$

$$= \frac{\frac{6}{10} \cdot \frac{5}{6} \cdot \frac{4}{6}}{\left(\frac{6}{10} \cdot \frac{5}{6} \cdot \frac{4}{6}\right) + \left(\frac{4}{10} \cdot \frac{1}{4} \cdot \frac{1}{4}\right)} = 0.93$$

회사	이전 법적문제	회사규모	상태
1	yes	small	정직
2	no	small	정직
3	no	large	정직
4	no	large	정직
5	no	small	정직
6	no	small	정직
7	yes	small	사기
8	yes	large	사기
9	no	large	사기
10	yes	large	사기

Naive Bayes Classifier 장단점

- 장점
 - 범주형 변수 처리
 - 단순성, 계산 효율성,
 - 좋은 분류성능,
- 단점
 - 많은 데이터 필요
 - 값이 0일 확률 처리 : Laplace smoothing

Naive Bayes 개선 - Laplace smoothing

- 입력 텍스트가 기존에 계산한 확률이 존재하지 않을 경우 0으로 계산될 수 있음
- 예시 : w_n 라는 신규 단어가 입력되는 경우. 각 확률은 0으로 계산됨
 - $P(\text{정상 메일} | \text{입력 텍스트}) = P(w_1 | \text{정상 메일}) * P(w_2 | \text{정상 메일}) * P(w_3 | \text{정상 메일}) * P(w_n | \text{정상 메일}) * P(\text{정상 메일})$
 - $P(\text{스팸 메일} | \text{입력 텍스트}) = P(w_1 | \text{스팸 메일}) * P(w_2 | \text{스팸 메일}) * P(w_3 | \text{스팸 메일}) * P(w_n | \text{정상 메일}) * P(\text{스팸 메일})$
- 분자와 분모에 일정 상수(k)를 더하여 신규 단어가 출현했을 때 0으로 계산되는 것을 방지

$$P(w_i | \text{positive}) = \frac{k + \text{count}(w_i, \text{positive})}{2k + \sum_{w \in V} (w, \text{positive})}$$

Naive Bayes 개선 - Log 이용 언더 플로우 방지

- 확률을 계산하고 확률간의 곱으로 연산이 이루어짐
- 1이하 값으로 이루어지는 값을 계속 해서 곱하면 소수점 이하로 계속 작아서 계산할수 없는 범위 이하로 작아지는 것을 언더플로우(underflow)라고 함
- Log의 성질을 활용하여 곱셈을 덧셈으로 변환하여 underflow를 방지

$$\log A \cdot B = \log A + \log B$$

$$\prod_i P(word_i|Pos) = \exp \left[\sum_i \{ \log P(word_i|Pos) \} \right]$$

예제 : 스팸 필터링

-	메일로부터 토큰화 및 정제 된 단어들	분류
1	me free lottery	스팸 메일
2	free get free you	스팸 메일
3	you free scholarship	정상 메일
4	free to contact me	정상 메일
5	you won award	정상 메일
6	you ticket lottery	스팸 메일

위 표로 스팸/정상 메일을 학습 = 확률을 계산
 “free lottery”라는 토큰이 있는 메일이 스팸일 확률은?

예제 : 스팸 필터링

- 우리가 구하고자 하는 것 (목표)
 - $P(\text{Normal} \mid \text{Words})$ = 입력 텍스트가 있을 때 정상 메일일 확률
 - $P(\text{Spam} \mid \text{Words})$ = 입력 텍스트가 있을 때 스팸 메일일 확률
- 계산 방법

$$P(\text{Normal} \mid \text{Words}) = \frac{P(\text{Words} \mid \text{Normal}) \cdot P(\text{Normal})}{P(\text{Words} \mid \text{Normal}) \cdot P(\text{Normal}) + P(\text{Words} \mid \text{Spam}) \cdot P(\text{Spam})}$$

$$P(\text{Spam} \mid \text{Words}) = \frac{P(\text{Words} \mid \text{Spam}) \cdot P(\text{Spam})}{P(\text{Words} \mid \text{Normal}) \cdot P(\text{Normal}) + P(\text{Words} \mid \text{Spam}) \cdot P(\text{Spam})}$$

예제 : 스팸 필터링

- 계산

$$P(Normal \mid Words) = \frac{P(Words|Normal) \cdot P(Normal)}{P(Words|Normal) \cdot P(Normal) + P(Words|Spam) \cdot P(Spam)}$$

$$P(Spam \mid Words) = \frac{P(Words|Spam) \cdot P(Spam)}{P(Words|Normal) \cdot P(Normal) + P(Words|Spam) \cdot P(Spam)}$$

- 계산 방법 => 입력되는 각 단어의 조건부 확률의 곱으로 표현 가능

$$P(Words \mid Normal) \cdot P(Normal) = P(w1 \mid Normal) \cdot P(w2 \mid Normal) \cdot P(Normal)$$

$$P(Words \mid Spam) \cdot P(Spam) = P(w1 \mid Spam) \cdot P(w2 \mid Spam) \cdot P(Spam)$$

예제 : 스팸 필터링

-	메일로부터 토큰화 및 정제 된 단어들	분류
1	me free lottery	스팸 메일
2	free get free you	스팸 메일
3	you free scholarship	정상 메일
4	free to contact me	정상 메일
5	you won award	정상 메일
6	you ticket lottery	스팸 메일

$$P(Normal \mid free, lottery)$$

$$= \frac{P(free|Normal) \cdot P(lottery|Normal) \cdot P(Normal)}{P(free|Normal) \cdot P(lottery|Normal) \cdot P(Normal) + P(free|Spam) \cdot P(lottery|Spam) \cdot P(Spam)}$$

$$P(Spam \mid free, lottery)$$

$$= \frac{P(free|Spam) \cdot P(lottery|Spam) \cdot P(Spam)}{P(free|Spam) \cdot P(lottery|Spam) \cdot P(Spam) + P(free|Normal) \cdot P(lottery|Normal) \cdot P(Normal)}$$

위 표로 스팸/정상 메일을 학습 = 확률을 계산
“free lottery”라는 토큰이 있는 메일이 스팸일 확률은?

예제 : 스팸 필터링

-	메일로부터 토큰화 및 정제 된 단어들	분류
1	me free lottery	스팸 메일
2	free get free you	스팸 메일
3	you free scholarship	정상 메일
4	free to contact me	정상 메일
5	you won award	정상 메일
6	you ticket lottery	스팸 메일

tokens 분류	spam	normal	P(w spam)	P(w normal)
award	0	1	4.55%	13.64%
contact	0	1	4.55%	13.64%
free	3	2	31.82%	22.73%
get	1	0	13.64%	4.55%
lottery	2	0	22.73%	4.55%
me	1	1	13.64%	13.64%
scholarship	0	1	4.55%	13.64%
ticket	1	0	13.64%	4.55%
to	0	1	4.55%	13.64%
won	0	1	4.55%	13.64%
you	2	2	22.73%	22.73%
합계	10	10		

Laplace smoothing 적용

$$P(\text{free} \mid \text{spam}) = \frac{k + \text{free}}{2 \cdot k + \text{spam}} = \frac{0.5 + 3}{2 \cdot 0.5 + 10} = 31.82\%$$

$$P(\text{lottery} \mid \text{spam}) = \frac{k + \text{lottery}}{2 \cdot k + \text{spam}} = \frac{0.5 + 2}{2 \cdot 0.5 + 10} = 22.73\%$$

예제 : 스팸 필터링

-	메일로부터 토큰화 및 정제 된 단어들	분류
1	me free lottery	스팸 메일
2	free get free you	스팸 메일
3	you free scholarship	정상 메일
4	free to contact me	정상 메일
5	you won award	정상 메일
6	you ticket lottery	스팸 메일

	$\text{Log}(P(w \text{spam}))$	$\text{Log}(P(w \text{normal}))$
award	-3.0910	-1.9924
contact	-3.0910	-1.9924
free	-1.1451	-1.4816
get	-1.9924	-3.0910
lottery	-1.4816	-3.0910
me	-1.9924	-1.9924
scholarship	-3.0910	-1.9924
ticket	-1.9924	-3.0910
to	-3.0910	-1.9924
won	-3.0910	-1.9924
you	-1.4816	-1.4816

예제 : 스팸 필터링

-	메일로부터 토큰화 및 정제 된 단어들	분류
1	me free lottery	스팸 메일
2	free get free you	스팸 메일
3	you free scholarship	정상 메일
4	free to contact me	정상 메일
5	you won award	정상 메일
6	you ticket lottery	스팸 메일

Log 이용 언더 플로우 방지

$$\begin{aligned}
 & P(\text{free} \mid \text{Normal}) * P(\text{lottery} \mid \text{Normal}) * P(\text{Normal}) \\
 &= \text{Exp}(\text{Log}(P(\text{free} \mid \text{Normal}) * P(\text{lottery} \mid \text{Normal}) * P(\text{Normal}))) \\
 &= \text{Exp}(\text{Log}(P(\text{free} \mid \text{Normal})) + \text{Log}(P(\text{lottery} \mid \text{Normal})) + \\
 &\quad \text{Log}(P(\text{Normal}))) \\
 &= \text{Exp}((-1.4816) + (-3.0910) + (-0.6931)) = \text{Exp}(-5.2658) \\
 &= 0.0052 = 0.52\%
 \end{aligned}$$

$$\begin{aligned}
 & P(\text{free} \mid \text{Spam}) * P(\text{lottery} \mid \text{Spam}) * P(\text{Spam}) \\
 &= \text{Exp}(\text{Log}(P(\text{free} \mid \text{Spam}) * P(\text{lottery} \mid \text{Spam}) * P(\text{Spam}))) \\
 &= \text{Exp}(\text{Log}(P(\text{free} \mid \text{Spam})) + \text{Log}(P(\text{lottery} \mid \text{Spam})) + \\
 &\quad \text{Log}(P(\text{Spam}))) \\
 &= \text{Exp}((-1.1451) + (-1.4816) + (-0.6931)) = \text{Exp}(-3.3199) \\
 &= 0.0362 = 3.62\%
 \end{aligned}$$

예제 : 스팸 필터링

$$\begin{aligned}
 & P(\text{free} \mid \text{Spam}) \cdot P(\text{lottery} \mid \text{Spam}) \cdot P(\text{Spam}) \\
 &= \text{Exp}(\log(P(\text{free} \mid \text{Spam}) \cdot P(\text{lottery} \mid \text{Spam}) \cdot P(\text{Spam}))) \\
 &= \text{Exp}(\log(P(\text{free} \mid \text{Spam})) + \log(P(\text{lottery} \mid \text{Spam})) + \log(P(\text{Spam}))) \\
 &= \text{Exp}((-1.4816) + (-3.0910) + (-0.6931)) = \text{Exp}(-5.2658) \\
 &= 0.0052 = 0.52 \%
 \end{aligned}$$

$$\begin{aligned}
 & P(\text{free} \mid \text{normal}) \cdot P(\text{lottery} \mid \text{normal}) \cdot P(\text{normal}) \\
 &= \text{Exp}(\log(P(\text{free} \mid \text{normal}) \cdot P(\text{lottery} \mid \text{normal}) \cdot P(\text{normal}))) \\
 &= \text{Exp}(\log(P(\text{free} \mid \text{normal})) + \log(P(\text{lottery} \mid \text{normal})) + \log(P(\text{normal}))) \\
 &= \text{Exp}((-1.1451) + (-1.4816) + (-0.6931)) = \text{Exp}(-3.3199) \\
 &= 0.0362 = 3.62 \%
 \end{aligned}$$

예제 : 스팸 필터링

-	메일로부터 토큰화 및 정제 된 단어들	분류
1	me free lottery	스팸 메일
2	free get free you	스팸 메일
3	you free scholarship	정상 메일
4	free to contact me	정상 메일
5	you won award	정상 메일
6	you ticket lottery	스팸 메일

- free, lottery가 포함된 메일이 스팸일 확률

$$= \frac{3.62\%}{0.52\%+3.62\%} = 87.5 \%$$

- free, lottery가 포함된 메일이 정상일 확률

$$= \frac{0.52\%}{0.52\%+3.62\%} = 12.5 \%$$

위 표로 스팸/정상 메일을 학습 = 확률을 계산
“free lottery”라는 토큰이 있는 메일이 스팸일 확률은?

감사합니다.

Insight⁺campus

